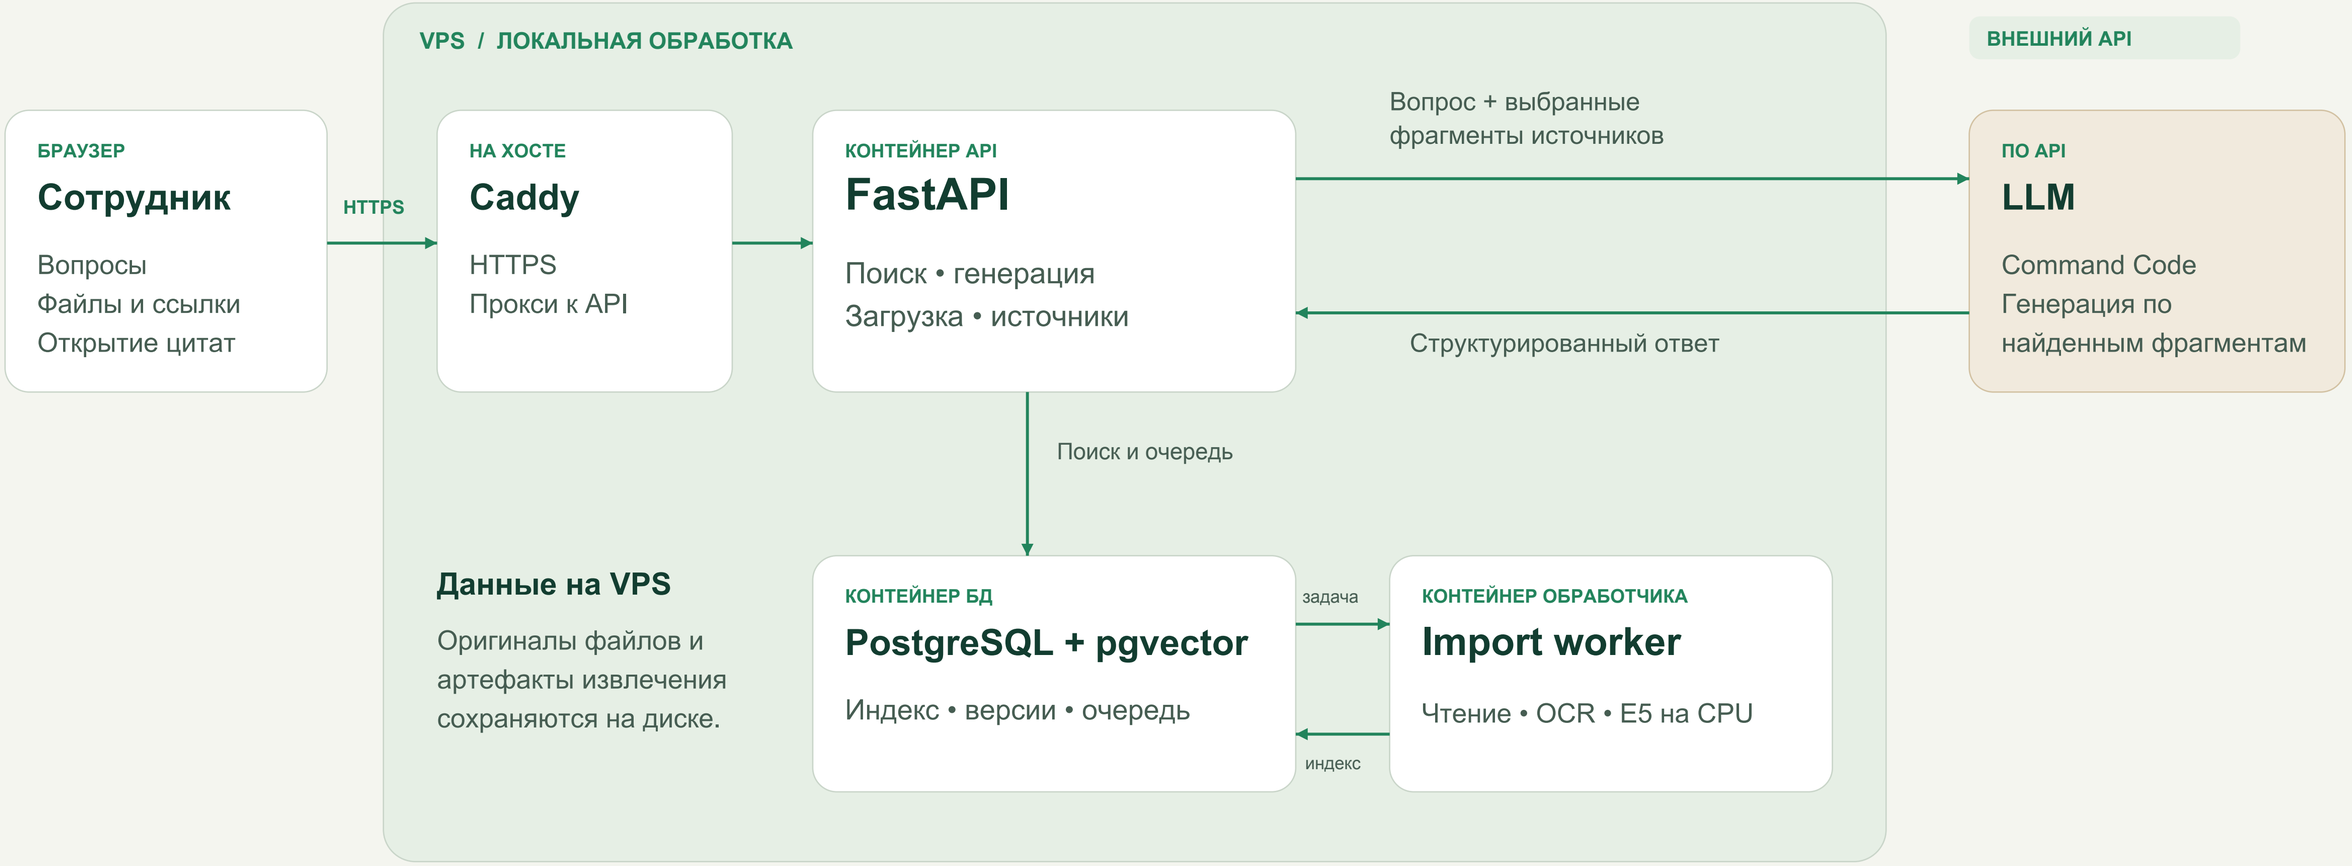
Как устроен бэкенд

Документ попадает в общую базу. Вопрос превращается в ответ с открываемыми источниками.



Общая база
Документы доступны всем посетителям

E5 работает локально
На VPS не требуется GPU

Сохраняем источник
Версия, фрагмент и координаты цитаты

Как новый документ попадает в поиск

Сохраняем оригинал, обрабатываем документ в фоне и одним переключением публикуем новый снимок индекса.

ЛОКАЛЬНО: ЧТЕНИЕ, OCR И ЭМБЕДДИНГИ

PDF / DOCX / XLSX • до 25 МБ на файл

01

ЭТАП 1

Принимаем файл

Файл или публичная ссылка
Проверка формата и размера
Оригинал остаётся на диске

02

ЭТАП 2

Ставим в очередь

Задача в PostgreSQL
Статус виден в браузере
Повтор после сбоя

03

ЭТАП 3

Извлекаем текст

Абзацы, пункты и таблицы
Для сканов — OCR
Предупреждения сохраняются

04

ЭТАП 4

Строим векторы

Текст → фрагменты
multilingual-e5-small
Только новый документ

05

ЭТАП 5

Публикуем индекс

Проверяем снимок базы
Атомарно меняем указатель
Документ доступен всем

Что происходит при повторной загрузке

БЕЗ ДУБЛЕЙ

Идентичные байты

SHA-256 совпал → сообщаем, что файл уже есть. Повторные фрагменты не создаются.

ЯВНОЕ ОБНОВЛЕНИЕ

Изменённый файл

Замена одноимённого документа требует разрешения. Старые версии и цитаты сохраняются.

ЧЕСТНЫЙ СТАТУС

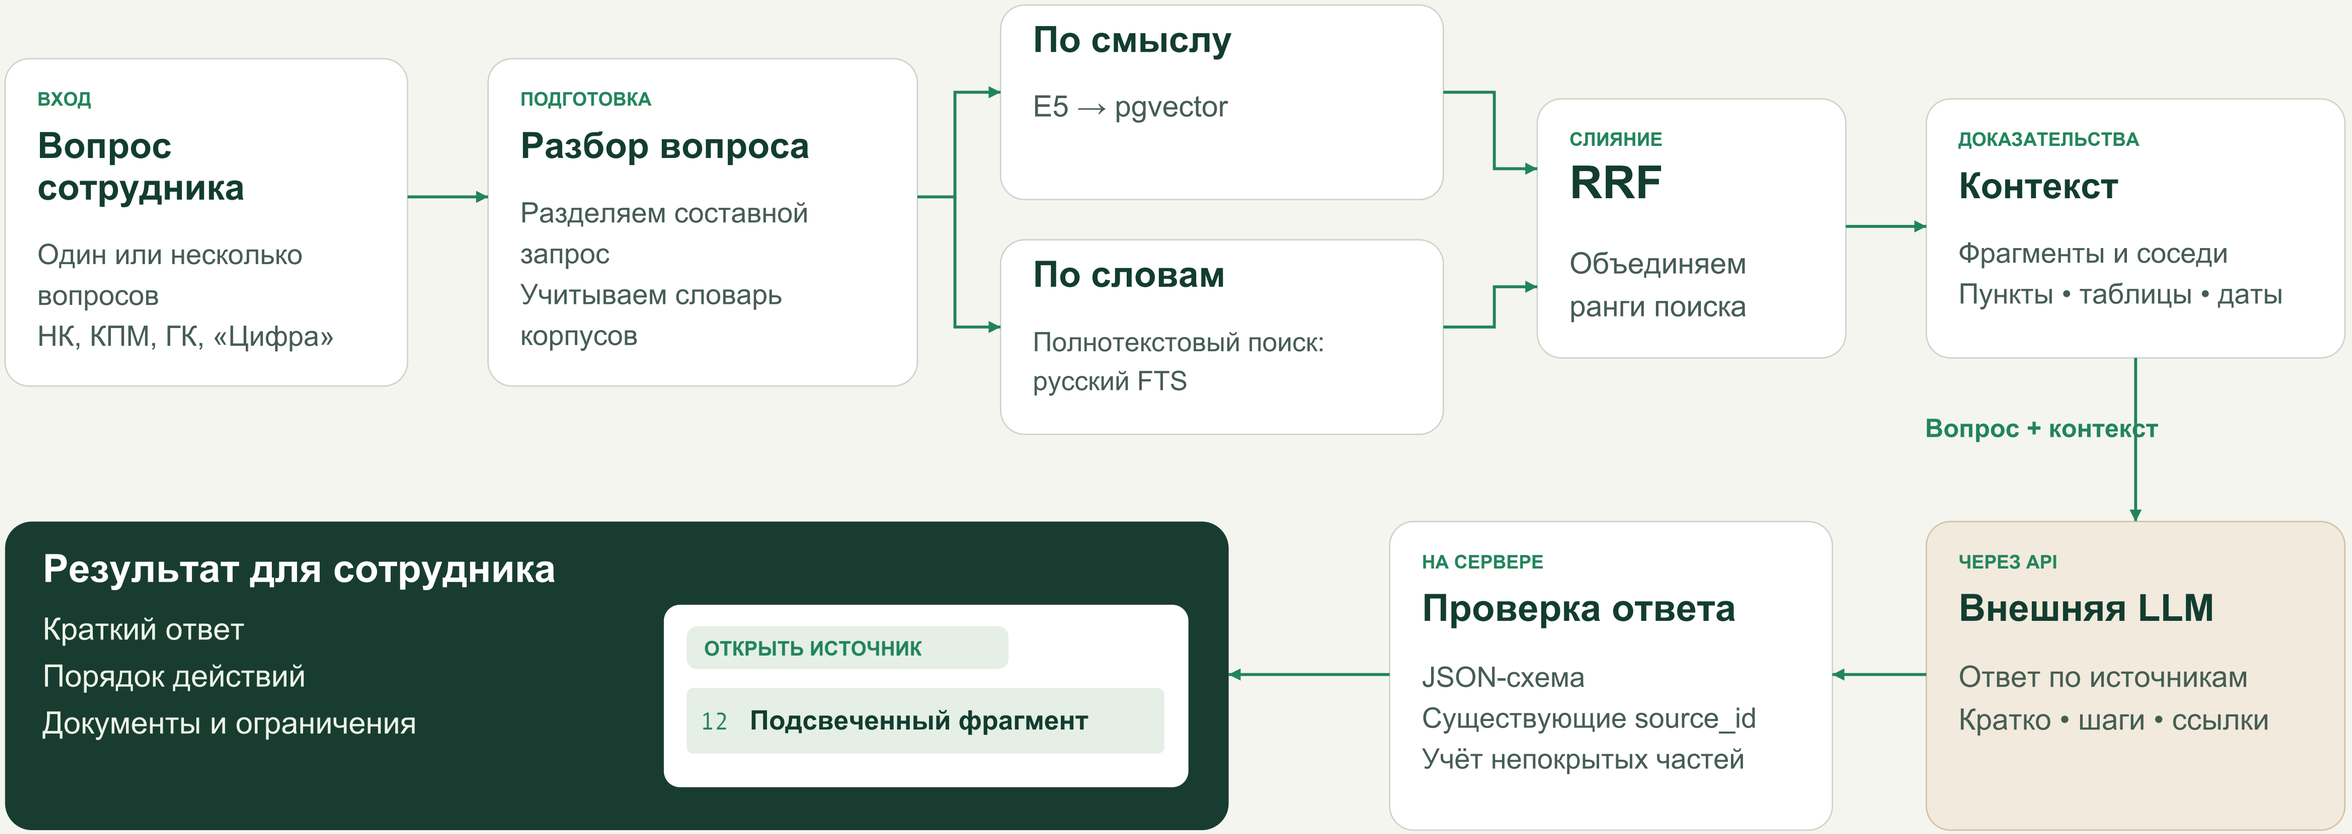
Ошибка или предупреждение

Сбой не меняет активный индекс. Неполное извлечение видно как частичный успех.

Обработчик не получает ключ LLM. Эмбеддинги остальных документов используются повторно.

Как вопрос становится проверяемым ответом

Сначала находим доказательства в базе, затем передаём их модели и открываем источники сотруднику.



Версия + блок + точные границы цитаты

Сервер проверяет структуру и координаты. Смысловую связь вывода с цитатой оценивает модель; OCR может ошибаться.

Карта основных модулей

Обязанности модулей. Пути указаны относительно src/navigator/.

01 ТОЧКИ ВХОДА

HTTP и интерфейс

`api.py`
FastAPI, поиск, ответы и открытие источников

`imports/routes.py`
Загрузка файла или публичной ссылки, статус задачи

`static/index.html`
Формы, шаги ответа и подсветка строк

02 ФОНОВЫЙ ПРОЦЕСС

Обработка файлов

`imports/worker.py`
Очередь и публикация индекса

`imports/download.py`
Скачивание публичных файлов

`ingest/pipeline.py`
Извлечение в отдельном процессе

`ingest/extractors.py`
PDF, DOCX, XLSX и OCR

`ingest/chunking.py`
Фрагменты с координатами

03 ЛОКАЛЬНЫЕ ВЫЧИСЛЕНИЯ

Поиск

`retrieval.py`
Составной запрос, слияние выдачи и добор контекста

`campus.py`
Пользовательский словарь сокращений корпусов

`ingest/embedding.py`
Локальные векторы E5: 384 измерения

04 КОНТРАКТ ОТВЕТА

Ответ и цитаты

`generation.py`
Вызов LLM, JSON-схема и существующие ссылки

`sources.py`
Версия, блок, границы цитаты и номера строк

Ответ различает:
подтверждённые сведения,
частичный результат,
нехватку данных, уточнение
и конфликт.

Общее хранилище `ingest/storage.py + ingest/schema.sql`

PostgreSQL / pgvector: документы, неизменяемые версии, фрагменты, снимки индекса и очередь импорта.

Два процесса приложения: API и import-worker. PostgreSQL работает в отдельном контейнере.